

Chronic Kidney Disease

Was fehlende Werte über ein Modell verraten

EDA, Missingness und fold-sichere LOOCV

Natasza Szczypien

Data Analytics mit Python · September 2026

Datensatz und Klassenverteilung

UCI Chronic Kidney Disease

400

Patienten


24

Eingabevariablen

2

Zielklassen


- **Echte Krankenhausdaten** aus einem Zeitraum von ungefähr zwei Monaten
- Numerische und kategoriale Merkmale
- Zielvariable: ckd oder notckd (*chronische Nierenkrankheit*)
- Fehlende Werte in vielen Parametern
- URL:
<https://archive.ics.uci.edu/dataset/336/chronic+kidney+disease>




CKD: 250 (62,5 %) · Non-CKD: 150 (37,5 %)

Numerische Parameter

14 Messwerte und Laborparameter



Kürzel	Bedeutung
age	Alter
bp	Blutdruck
sg	Spezifisches Uringewicht
al	Albumin im Urin
su	Zucker im Urin
bgr	Zufallsblutzucker
bu	Blutharnstoff




Kürzel	Bedeutung
sc	Serumkreatinin
sod	Natrium
pot	Kalium
hemo	Hämoglobin
pcv	Packed Cell Volume
wbcc	Leukozytenzahl
rbcc	Erythrozytenzahl


Die Skalen unterscheiden sich stark. Für manche Variablen sind hohe Werte medizinisch plausibel und keine automatischen Datenfehler.

Kategoriale Parameter

10 klinische Befunde und Begleiterkrankungen



Kürzel	Bedeutung
rbc	Rote Blutkörperchen im Urin
pc	Eiterzellen
pcc	Eiterzellklumpen
ba	Bakterien
htn	Bluthochdruck




Kürzel	Bedeutung
dm	Diabetes mellitus
cad	Koronare Herzkrankheit
appet	Appetit
pe	Periphere Ödeme
ane	Anämie


Für Machine Learning werden Kategorien innerhalb der Trainingsdaten imputiert und anschließend kodiert.

Missingness ist ungleich über die Klassen verteilt

Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert



■ Vollständig ■ Mindestens ein Wert fehlt




Fisher-Test: Odds Ratio 0,063 · p < 0,001



Missingness und CKD-Status sind in diesem Datensatz stark assoziiert.

Missingness ist ungleich über die Klassen verteilt

Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert



■ Vollständig ■ Mindestens ein Wert fehlt



Fisher-Test: Odds Ratio 0,063 · p < 0,001

Missingness und CKD-Status sind in diesem Datensatz stark assoziiert.

Idee: Wir analysieren nur Complete cases und den incomplete entfernen wir.

Complete Case

Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	Wert

Alle wichtigen Felder sind ausgefüllt.


Incomplete Case

Wert		Wert	Wert	Wert
Wert	Wert	Wert		Wert
	Wert	Wert	Wert	Wert
Wert	Wert	Wert	Wert	

Mindestens ein Feld fehlt.


Incomplete bedeutet nicht leer. Es bedeutet nur: Mindestens ein Wert dieser Patientenzeile fehlt.

Warum eine Analyse nur mit complete case problematisch ist



Die Auswahl vollständiger Fälle verändert die Population systematisch. Die Klassenverteilung ändert sich dadurch.


Warum eine Analyse nur mit complete case problematisch ist




Die Auswahl vollständiger Fälle verändert die Population systematisch. Die Klassenverteilung ändert sich dadurch.

Fehlende Werte pro Parameter

Die zwölf am stärksten betroffenen Merkmale




Warum sich die Fragestellung verändert hat



Die Missingness wurde damit selbst zum Untersuchungsgegenstand.

Leave-One-Out-Cross-Validation

Jede Person wird genau einmal unabhängig vorhergesagt



Dieser Ablauf wird 400-mal wiederholt

Am Ende besitzt jede Person eine Vorhersage aus einem Modell, das sie nicht gesehen hat.


Wichtig: Auch Median, Modus, KNN und Skalierung werden in jedem Trainingsdurchlauf neu gelernt.

Random Forest als Hauptmodell

Viele Entscheidungsbäume stimmen gemeinsam über die Klasse ab

Warum passt das Modell zu diesem Datensatz?

- Es verarbeitet numerische und kodierte kategoriale Merkmale gemeinsam.
- Es kann nichtlineare Zusammenhänge und Interaktionen erfassen.
- Die numerischen Variablen müssen nicht standardisiert werden.
- Die Merkmalsbedeutung lässt sich anschließend untersuchen.




**Ein Random Forest erkennt jedes Muster, das die Klassen trennt.
Dazu können medizinische Werte gehören, aber auch unerwünschte Dokumentationsmuster.**

Logistische Regression als Vergleichsmodell

Ein einfacheres Modell prüft, ob schon eine lineare Kombination der Merkmale ausreicht

Warum verwenden wir sie?

- Sie liefert eine einfachere Referenz für den Random Forest.
- Sie kann fehlende Werte nicht direkt verarbeiten und benötigt deshalb eine Imputation.
- Sie bildet ohne zusätzliche Terme keine komplexen nichtlinearen Interaktionen ab.
- Weil deine Zielvariable eine **Klasse** ist



Auch die logistische Regression erreicht mit Missing-Indikatoren 0,998 Balanced Accuracy. Die starke Trennung hängt also nicht nur von komplexen Bäumen ab.


Verglichene Modellstrategien

Hauptvergleich: LOOCV auf allen 400 Patienten

Experiment	Eingaben	Missingness	Kurz erklärt	Frage
RF Native Missing	Alle Merkmale	Numerische NaN bleiben erhalten	Ganzer Datensatz unverändert	Wie gut funktioniert die direkte Verarbeitung?

1 · Originaldaten

Patient	bp	hemo
A	80	14,0
B	fehlt	fehlt
C	90	10,0



Verglichene Modellstrategien

Hauptvergleich: LOOCV auf allen 400 Patienten

Experiment	Eingaben	Missingness	Kurz erklärt	Frage
RF Native Missing	Alle Merkmale	Numerische NaN bleiben erhalten	Ganzer Datensatz unverändert	Wie gut funktioniert die direkte Verarbeitung?
RF Median/Modus	Alle Merkmale	Median + Modus	Ersetzt Lücken aus den Trainingsdaten und klassifiziert danach mit einem Random Forest.	Reicht eine einfache Imputation?
RF + Indikatoren	Alle Merkmale	Imputation + 0/1-Indikatoren	Zusätzliche Spalten zeigen, welche Werte ursprünglich gefehlt haben.	Liefert Missingness zusätzliche Information?
RF KNN/Modus	Alle Merkmale	KNN + Modus	Schätzt numerische Lücken aus ähnlichen Trainingspatienten. Kategorien erhalten den Modus.	Ist KNN besser als der Median?
Logistische Regression	Alle Merkmale	Median/Modus, mit und ohne Indikatoren	Gewichtet die Merkmale und berechnet daraus eine CKD-Wahrscheinlichkeit.	Reicht eine lineare Trennung?

Zusatzanalyse: Ein separates Random-Forest-Modell verwendete nur die 158 Complete Cases.

Vom fehlenden Wert zum Missing-Indikator

Ein vereinfachtes Beispiel mit Blutdruck und Hämoglobin

1 · Originaldaten

Patient	bp	hemo
A	80	14,0
B	fehlt	fehlt
C	90	10,0

2 · Imputation plus Indikatoren

Patient	bp	bp_missing	hemo	hemo_missing
A	80	0	14,0	0
B	80*	1	12,0*	1
C	90	0	10,0	0

0 = Wert war beobachtet

1 = Wert fehlte ursprünglich

* Beispielwert wurde imputiert


Das Modell erhält anschließend zwei Informationen

- den ausgefüllten Messwert
- die Information, ob der Messwert ursprünglich fehlte

In jeder LOOCV-Runde lernt die Pipeline die Imputationswerte nur aus den 399 Trainingsfällen.

Ergebnisse der vollständigen Modelle

Balanced Accuracy aus der LOOCV



- Mit Missing-Indikatoren bleibt nur ein Fehler.
- Median/Modus verursacht drei, KNN sechs Fehler.
- Die Unterschiede betreffen nur wenige Patienten.

Verglichene Modellstrategien

Hauptvergleich: LOOCV auf allen 400 Patienten

Experiment	Eingaben	Missingness	Kurz erklärt	Frage
RF Native Missing	Alle Merkmale	Numerische NaN bleiben erhalten	Ganzer Datensatz unverändert	Wie gut funktioniert die direkte Verarbeitung?
RF Median/Modus	Alle Merkmale	Median + Modus	Ersetzt Lücken aus den Trainingsdaten und klassifiziert danach mit einem Random Forest.	Reicht eine einfache Imputation?
RF + Indikatoren	Alle Merkmale	Imputation + 0/1-Indikatoren	Zusätzliche Spalten zeigen, welche Werte ursprünglich gefehlt haben.	Liefert Missingness zusätzliche Information?
RF KNN/Modus	Alle Merkmale	KNN + Modus	Schätzt numerische Lücken aus ähnlichen Trainingspatienten. Kategorien erhalten den Modus.	Ist KNN besser als der Median?
Logistische Regression	Alle Merkmale	Median/Modus, mit und ohne Indikatoren	Gewichtet die Merkmale und berechnet daraus eine CKD-Wahrscheinlichkeit.	Reicht eine lineare Trennung?
Missingness-only	Nur 0/1-Indikatoren	Keine Imputation nötig	Verwendet keine Messwerte, sondern ausschließlich das Muster der fehlenden Untersuchungen.	Wie stark ist das Fehlermuster allein?

Zusatzanalyse: Ein separates Random-Forest-Modell verwendete nur die 158 Complete Cases.


Verglichene Modellstrategien

Hauptvergleich: LOOCV auf allen 400 Patienten

Experiment	Eingaben	Missingness	Kurz erklärt	Frage
Missingness-only	Nur 0/1-Indikatoren	Keine Imputation nötig	Verwendet keine Messwerte, sondern ausschließlich das Muster der fehlenden Untersuchungen.	Wie stark ist das Fehlermuster allein?


2 · Imputation plus Indikatoren

Patient	bp	bp_missing	hemo	hemo_missing
A	80	0	14,0	0
B	80*	1	12,0*	1
C	90	0	10,0	0



Was sagen die Ergebnisse?

Missingness-only als Kontrollversuch



Kernaussagen

- Medizinische Messwerte liefern den größten Teil der Trennschärfe.
- Aber ...
- **Missingness allein erreicht bereits 0,833 Balanced Accuracy.**
- Das Modell nutzt deshalb auch Informationen aus dem Erhebungsprozess.
- Interne LOOCV zeigt **keine Übertragbarkeit auf andere Kliniken oder Populationen.**



Fazit: Gute Vorhersageleistung braucht eine kritische Prüfung darauf, was das Modell tatsächlich gelernt hat.


Statistische Tests bestätigen das interne Signal

Sie beantworten nicht die Frage nach anderen Kliniken

Prüfung	Ergebnis	Interpretation
Fisher-Exakt-Test	OR = 0,063 $p = 6,65 \times 10^{-33}$	Missingness und CKD-Status hängen sehr stark zusammen.
McNemar, Native gegen Indikatoren	0 gegen 1 Fehler $p = 1,00$	Das Native-Missing-Modell klassifizierte einen Patienten mehr korrekt . Bei den übrigen 399 Patienten unterschieden sich die Modelle nicht. Dieser einzelne Fall reicht nicht aus, um zu belegen, dass das Native-Missing-Modell grundsätzlich besser ist ($p = 1,00$).
McNemar, Native gegen Median und KNN	Median: $p = 0,25$ KNN: $p = 0,031$	KNN ist nur nominal schwächer. Nach Holm-Korrektur ergibt sich $p = 0,094$.
Exaktes 95%-Intervall	Accuracy 1,000 ungefähr 0,991 bis 1,000	Auch 400 korrekte Vorhersagen garantieren keine fehlerfreie zukünftige Anwendung.

Wichtigste Merkmale laut Random Forest

Modell mit Median/Modus und Missing-Indikatoren



Die Importance zeigt den Beitrag zur Vorhersage in diesem Modell. Sie beweist weder Kausalität noch medizinische Eigenständigkeit eines Merkmals.

Trennrichtung im Datensatz

- Bei CKD höher: sc, al, bu, htn und dm
- Bei CKD niedriger: hemo, pcv, rbcc und sg
- hemo, pcv und rbcc beschreiben ähnliche Blutbildinformationen
- Die Prozentwerte zeigen die relative Bedeutung eines Merkmals innerhalb dieses Modells. Sie zeigen weder, wie gut das Merkmal allein trennt, noch einen ursächlichen medizinischen Einfluss.
- Besonders **das Fehlen** von rbc, rbcc, pot, wbcc und sod **lieferte Vorhersageinformation**. Das beschreibt auch den Erhebungsprozess.

Medizinische Einordnung der Modellmerkmale

Plausibilität ersetzt keine externe klinische Validierung

Merkmal	Muster bei CKD	Einfache medizinische Erklärung	Bedeutung
sc · Kreatinin	höher	Gesunde Nieren filtern Kreatinin aus dem Blut. Ein hoher Wert kann auf eine eingeschränkte Nierenfunktion hinweisen.	zentral
al · Albumin im Urin	höher	Albumin ist ein Eiweiß, das normalerweise kaum in den Urin gelangt. Größere Mengen können auf eine Schädigung der Nierenfilter hinweisen.	zentral
hemo, pcv, rbcc	niedriger	Erkrankte Nieren können zu wenig von einem Signalstoff für die Bildung roter Blutkörperchen produzieren. Dadurch kann eine Blutarmut entstehen.	plausible Folge
htn, dm	häufiger	Bluthochdruck und Diabetes können die feinen Blutgefäße der Nieren langfristig schädigen.	Risikofaktoren
bu · Blutharnstoff	höher	Harnstoff ist ein Abfallstoff. Wenn die Nieren schlechter arbeiten, kann sich mehr davon im Blut ansammeln. Der Wert wird aber auch durch andere Faktoren beeinflusst.	unterstützend
sg · Uringewicht	niedriger	Das Uringewicht zeigt, wie gut die Nieren den Urin konzentrieren können. Ein niedriger Wert kann auf eine eingeschränkte Konzentrationsfähigkeit hinweisen.	


Medizinisch bestätigt ist die grundsätzliche Plausibilität. Nicht bestätigt ist, dass dieses Modell in anderen Kliniken dieselbe Leistung erreicht.

Quellen: KDIGO 2024 und NIDDK


Anämieparameter und Risikofaktoren

CKD rot, Non-CKD grün


hemo · Hämoglobin




pcv · Packed Cell Volume



rbcc · Erythrozytenzahl



Bluthochdruck und Diabetes




Hämoglobin, PCV und Erythrozytenzahl liegen bei CKD niedriger. Bluthochdruck und Diabetes treten häufiger auf.


Nierenbezogene Merkmale nach CKD-Status

CKD rot, Non-CKD grün, relative Verteilungen innerhalb der Klassen


sc · Kreatinin




bu · Blutharnstoff



al · Albumin im Urin




sg · Spezifisches Uringewicht



Bei Kreatinin und Blutharnstoff fasst die letzte Klasse die höchsten 1 % der Werte zusammen.

Nierenbezogene Merkmale nach CKD-Status

- Man erkennt bei einigen klinischen Parametern deutliche Unterschiede zwischen CKD und notCKD.
- Ich würde sie aber nicht ohne Weiteres auf eine allgemeine Patientenpopulation übertragen.
- Wir haben einen deutlichen Bias beziehungsweise eine Selektion durch den Erhebungsprozess, weil fehlende Werte stark mit dem CKD-Status zusammenhängen.
- Deshalb zeigen die Plots ein Signal, aber wir wissen noch nicht, wie generalisierbar dieses Signal ist.



Endinterpretation

Was bedeutet das Ergebnis für diesen Datensatz?

Was die Daten zeigen

- Medizinische Parameter unterscheiden CKD und Non-CKD deutlich.
- Mehrere Modelle erkennen diese interne Trennung zuverlässig.
- Der Datensatz eignet sich gut zur Demonstration von Analyseverfahren.

Warum das problematisch ist



- Erkrankte und nicht erkrankte Patienten wurden offenbar **unterschiedlich vollständig untersucht oder dokumentiert.**



- Modelle können deshalb lernen: **Wenn eine Probe fehlt, spricht das für CKD.**
- Dieses Muster kann in einer anderen Klinik verschwinden.

Was ein gutes Modell lernen soll



- Die Krankheit soll sich in Laborwerten und klinischen Befunden zeigen.
- Das Modell **sollte nicht von zufälligen Lücken in der Dokumentation abhängen.**
- Neue Klinikdaten müssen diese Trennung unabhängig bestätigen.

Trotz des Bias ist der Datensatz nicht nutzlos. Er kann Hinweise liefern und Hypothesen erzeugen. Für belastbares medizinisches Wissen oder ein Diagnosetool brauchen wir aber bessere, vollständigere und externe Daten.